



# Quantum Reinforcement Learning to Solve Cart Pole Environment

Unidade curricular de ciência de dados quântica 14/06/2023



Maria Gabriela Jordão Oliveira, PG 50599 Miguel Caçador Peixoto, PG 50657





#### Conteúdos

- 01 → Introdução e Motivação
- 02 --- Quantum Machine Learning
- 03 --- Reinforcement Learning
- 04 → Implementação
- 05 → Resultados
- 06 → Conclusão

**01** →



## Introdução e Motivação

#### (+) Interesse na Computação Quântica --->

Explorando as propriedades intrínsecas da mecânica quântica e com aplicações em diversas áreas.

#### (+) Aparecimento de paradigmas de ML ----

Aparecimento de paradigmas poderosos, tal como o reinforcement learning.

#### 

Problemas de escalabilidade e eficiência das máquinas clássicas ao resolver tarefas complexas.




#### **Quantum Reinforcement Learning**

**02** →

### Quantum Machine Learning




#### Circuitos Quânticos Variacionais




# 03 — Reinforcement Learning




#### Q - Learning




#### Q - Learning




#### **Policy Gradient**






#### **Policy Gradient**



03 → Implementação



#### Ambiente - Cart Pole (v1)

Action Space	Discrete(2)	
Observation Shape	(4,)	
Observation High	[4.8 inf 0.42 inf]	
Observation Low	[-4.8 -inf -0.42 -inf]	

Posição e velocidade do carrinho e ângulo e velocidade angular do poste

O jogo termina quando o poste ultrapassa um certo ângulo, o carrinho ultrapassa os limites do jogo ou se excede os 500 passos temporais.


#### Arquitetura dos Circuitos Quânticos




#### **Embedding dos dados**


$$|\psi_X\rangle = \bigotimes_{i=1}^N R_X(x_i) = \bigotimes_{i=1}^N \left[\cos\left(\frac{x_i}{2}\right)|0\rangle - i\sin\left(\frac{x_i}{2}\right)|1\rangle\right]$$

#### Entrelaçamento





#### Modelo clássico



DNN convencional com 10 neurônios por camada escondida, 4 na camada de input e 2 na de saída.

#### Treino

Q-Learning **Policy Gradient Epsilon Greedy** Start GRAND OPENING! Exploration Exploitation Select Best Known Action Select Random Action

#### Treino


Variable HP	Values	
Data Re-Uploading	{0, 1}	
Entanglement Type	$\{CX, CZ\}$	
<b>Entanglement Format</b>	{Ladder, C	ircular}
Number of Layers	[1, 8]	
Fixed HP		Values
Batch Size		16
Learning Rate (LR)		0.001
Learning Rate (IO Scali	ng)	0.01
$\epsilon_0$		1
$\epsilon_{decay}$		0.99
$\epsilon_{min}$		0.01
Buffer Size		0.01
Target Update Frequency (Steps)		5
Online Train Frequency (Steps)		1
Win Threshold (Episodes)		100


As diferentes arquiteturas são treinadas ao longo de 5000 episódios, com condições de 'early stopping' de ganhar 100 episódios consecutivos.


#### **Teste**


100 jogos tendo em conta os modelos previamente treinados.

## 05 → Resultados









## 05 → Conclusão





